




Proyecto de Machine Learning sobre COVID-19

JUAN ANDRES MORERA RAMIREZ-2243581
DIEGO JAVIER QUINTERO OJEDA-2243593
JOHAN STIP CHAPARRO GUERRERO-2243677

CONTENIDOS

01. Objetivo






02. Análisis de variables

03. Modelos Supervisados

04. Deep Learning

05. Aprendizaje No Supervisado


06. Conclusión





INTRODUCCION

El COVID-19 generó un gran impacto mundial y produjo enormes cantidades de datos médicos. En este proyecto se aplicaron técnicas de Machine Learning para analizar pacientes, identificar patrones y construir modelos predictivos relacionados con la enfermedad.



01.

OBJETIVO

OBJETIVO

Analizar datos clínicos relacionados con el COVID-19 para identificar patrones y factores de riesgo en los pacientes.

#1



Desarrollar modelos de Aprendizaje de Máquinas capaces de predecir la gravedad o presencia de complicaciones asociadas al COVID-19.


#2



Comparar diferentes algoritmos de Machine Learning y Deep Learning para determinar cuál ofrece el mejor rendimiento y precisión en la clasificación de pacientes.


#3






02.

Análisis de variables



Análisis de variables



Descripción del Dataset

- Dataset: COVID-19 Dataset (Kaggle - Meir Nizri).
- Más de 1 millón de registros clínicos.
- Variables demográficas y médicas.
- Datos relacionados con hospitalización y gravedad.

14

Columnas Totales

Hay 1.048.574 características
+ 1 etiqueta

Objetivo del Análisis

- Explorar relaciones entre variables clínicas y gravedad del COVID-19.
- Construir modelos predictivos.
- Comparar algoritmos supervisados y no supervisados.

1.048.575

Registros Médicos

Casos completos tras
limpieza

100%


Datos Limpios

Sin valores nulos

Distribución y Desbalance de Clase


Compara Distribución

Distribución de pacientes por sexo




Balance De Cantidad Por Edad

Pacientes por edad



Clasificación Por Enfermedad

Cantidad de personas con enfermedades



Three clusters of glowing pink spheres are positioned on the left side of the image. The top-left cluster is the largest, the top-right cluster is medium-sized, and the bottom-left cluster is also large. Each sphere has a bright pink highlight and a subtle texture of fine white dots. The background is a dark green gradient.

03.

Modelos Supervisados

Modelos Supervisados

1# Decision Tree



2# Random Forest



3# Support Vector Machine (SVM)



4# Evaluacion



Con Accuracy, Precision,
Recall y F1-Score

```
# DT (Tuning max_depth)
dt_final = DecisionTreeClassifier(max_depth=10, random_state=21).fit(X_train_top, y_train)

# RF (Tuning n_estimators)
rf_final = RandomForestClassifier(n_estimators=100, random_state=21).fit(X_train_top, y_train)

# SVC (Linear/max_iter)
svc_final = LinearSVC(random_state=21, max_iter=1000).fit(X_train_top, y_train)
```

RANKING DE IMPORTANCIA DE TODAS LAS COLUMNAS:

PATIENT_TYPE	0.948270
AGE	0.033213
OBESITY	0.004033
SEX	0.003577
DIABETES	0.003043
OTHER_DISEASE	0.001489
RENAL_CHRONIC	0.001209
HIPERTENSION	0.001102
ASTHMA	0.000960
INMSUPR	0.000924
COPD	0.000923
TOBACCO	0.000707
CARDIOVASCULAR	0.000552

dtype: float64

Las 2 columnas elegidas para el re-entrenamiento: ['PATIENT_TYPE', 'AGE']

RESULTADOS DE CLASIFICACIÓN (Solo Top 2):

Accuracy Decision Tree: 0.8924
Accuracy Random Forest: 0.8924
Accuracy SVC (Linear): 0.8889

Cross Validation

- Uso de validación cruzada para evaluar estabilidad del modelo.
- Reducción del sobreajuste.
- Comparación más confiable entre algoritmos.


```
# --- Modelos ---"Definimos los modelos"
dt = DecisionTreeClassifier(max_depth=5, random_state=21)
rf = RandomForestClassifier(n_estimators=10, random_state=21)
svc = LinearSVC(random_state=42, max_iter=500)#Support Vector Classifier(Clasificador de Vectores de Soporte)

# --- Cross Validation k=10, 20, 50 ---"Probamos 3 configuraciones de k"
for k in [10, 20, 50]:
    kf = StratifiedKFold(n_splits=k, shuffle=True, random_state=21)#divide los datos en k (folds)
    dt_scores = cross_val_score(dt, X, y, cv=kf, scoring='accuracy')#10 es estandar
    rf_scores = cross_val_score(rf, X, y, cv=kf, scoring='accuracy')#20 es mas preciso
    svc_scores = cross_val_score(svc, X, y, cv=kf, scoring='accuracy')#50 es exigente
```

```
===== CROSS VALIDATION (k=10) =====
Decision Tree -> Promedio: 0.8777 | Std: 0.0158
Random Forest -> Promedio: 0.8723 | Std: 0.0144
SVC Lineal -> Promedio: 0.8860 | Std: 0.0113
```

```
===== CROSS VALIDATION (k=20) =====
Decision Tree -> Promedio: 0.8743 | Std: 0.0192
Random Forest -> Promedio: 0.8680 | Std: 0.0234
SVC Lineal -> Promedio: 0.8857 | Std: 0.0206
```

```
===== CROSS VALIDATION (k=50) =====
Decision Tree -> Promedio: 0.8790 | Std: 0.0318
Random Forest -> Promedio: 0.8717 | Std: 0.0353
SVC Lineal -> Promedio: 0.8860 | Std: 0.0326
```



04.

Deep Learning

Deep Learning

- Red neuronal densa implementada con TensorFlow/Keras.
- Capas ocultas con funciones ReLU.
- Entrenamiento usando datos escalados.
- Evaluación mediante métricas de clasificación.

===== PUNTO 5 - DEEP LEARNING: PERCEPTRÓN MULTICAPA =====

Config1 - 3 capas	(64, 128, 128)		Épocas: 10	->	Accuracy: 11.50%
Config1 - 3 capas	(64, 128, 128)		Épocas: 50	->	Accuracy: 11.50%
Config1 - 3 capas	(64, 128, 128)		Épocas: 100	->	Accuracy: 11.50%
Config2 - 6 capas	(64,64,128,128,256,256)		Épocas: 10	->	Accuracy: 11.50%
Config2 - 6 capas	(64,64,128,128,256,256)		Épocas: 50	->	Accuracy: 11.50%
Config2 - 6 capas	(64,64,128,128,256,256)		Épocas: 100	->	Accuracy: 11.50%
Config3 - 10 capas	(128 neuronas cada una)		Épocas: 10	->	Accuracy: 0.00%
Config3 - 10 capas	(128 neuronas cada una)		Épocas: 50	->	Accuracy: 0.00%
Config3 - 10 capas	(128 neuronas cada una)		Épocas: 100	->	Accuracy: 0.00%

Época más conveniente: Config1 - 3 capas (64, 128, 128) | Épocas: 10
Accuracy obtenido: 11.50%



05.

Aprendizaje No Supervisado


PCA


Se aplicó PCA para reducir la cantidad de variables del dataset y simplificar los datos sin perder demasiada información importante.

---Esto permitió---


- Visualizar mejor los datos.
- Reducir ruido y redundancia.
- Mejorar el rendimiento de algunos modelos.

Varianza total explicada: 0.27216551555944785





K-MEANS





Se utilizó el algoritmo K-Means para agrupar automáticamente pacientes con características similares relacionadas con el COVID-19.

Objetivos de K-Means:

- Detectar grupos de pacientes con comportamientos parecidos.
- Identificar posibles patrones de riesgo.
- Analizar si los pacientes enfermos podían separarse naturalmente en grupos.

Resultados Observados:

- Algunos clusters mostraron similitudes entre pacientes.
- No se encontró una separación completamente clara entre todos los casos.
- Esto indica que el comportamiento del COVID-19 es complejo y depende de múltiples factores clínicos.




DBSCAN

Se utilizó el algoritmo DBSCAN para agrupar pacientes con características similares relacionadas con el COVID-19.

---El objetivo fue---

- Detectar posibles grupos de pacientes.
- Identificar comportamientos similares.
- Encontrar patrones ocultos en los datos médicos.

Clusters encontrados: 3
Puntos de ruido: 128
Total puntos: 5000



The background is a dark green gradient with several glowing green, spherical virus-like particles. Each particle has a textured surface with small bumps and numerous spike-like protrusions of varying lengths. They are scattered across the frame, with some appearing larger and more detailed than others.

06.

CONCLUSION

CONCLUSIONES

K-Means Permitió Detectar Patrones

- El algoritmo agrupó pacientes con características similares relacionadas con el COVID-19, facilitando el análisis de comportamientos comunes.

Los Clusters No Fueron Totalmente Claros

- Aunque algunos grupos mostraron similitudes importantes, no existió una separación perfecta entre pacientes, evidenciando la complejidad del COVID-19.

El Aprendizaje No Supervisado Aporta Valor

- K-Means y PCA ayudaron a descubrir relaciones ocultas en los datos médicos, complementando los modelos supervisados y mejorando la interpretación visual de la información.

The background is a dark green gradient. It is decorated with several 3D-rendered virus-like particles. On the left side, there are five orange-red spherical particles with numerous red, spike-like protrusions. On the right side, there are four pinkish-red spherical particles covered in green, flower-like or hexagonal protrusions.

Gracias!

CREDITS: This presentation template was created by **Slidesgo**, and includes icons by **Flaticon** and infographics & images by **Freepik**